

Otimização de SLA e Triagem de Atendimento com IA

Matheus Guerra

Data Scientist • Operações de Crédito

Gerado em 21/07/2026 • github.com/MathGuerra/analizador-atendimento

1. Resumo Executivo & Desafio de Negócio

O atendimento financeiro e de crédito enfrenta diariamente um alto volume de solicitações, variando desde dúvidas simples até renegociações críticas e bloqueios de sistema. A triagem manual por ordem de chegada consome um tempo valioso de SLA (*Service Level Agreement*) e pode resultar na perda do momento ideal para reter clientes insatisfeitos ou com alto risco de *churn* (cancelamento).

Este projeto implementa um modelo de Inteligência Artificial baseado em **Processamento de Linguagem Natural (NLP)** capaz de classificar automaticamente o sentimento do cliente em tempo real, identificar palavras-chave de risco operacional (como "juros abusivos", "PROCON", "cancelamento") e priorizar o direcionamento para as equipes especializadas de retenção ou ouvidoria.

Impacto Operacional Estimado

Redução projetada de até **35% no tempo de espera** para resolução de chamados críticos de renegociação e crédito, automatizando 100% da triagem inicial sem intervenção humana.

2. Desempenho do Modelo (Baseline)

Acurácia Geral	Precisão (Críticos)	Tempo de Resposta
92.4%	89.8%	< 0.05s

3. Regra de Negócio e Matriz de Direcionamento

Sentimento	Gatilho de Texto (Palavras-Chave)	Ação Recomendada	Prioridade SLA
Negativo	"cancelar", "procon", "juros", "abusivo"	Retenção / Ouvidoria	P1 • Imediata (< 5 min)
Negativo	"caiu", "erro", "bloqueio", "aplicativo"	Suporte Técnico / TI	P2 • Alta (< 15 min)
Positivo	"liberar", "rápido", "atendente", "taxas"	Pesquisa NPS / Pós-venda	P3 • Padrão

4. Arquitetura do Sistema e Fluxo do Dado

Para garantir que o modelo opere sem criar gargalos na central de atendimento, a arquitetura foi projetada em um pipeline sequencial de baixa latência. Desde o momento do input do cliente no canal de atendimento, o dado é processado, vetorizado e avaliado pelas regras de negócio antes de chegar à tela do operador.

Input Cliente

→

Pré-processamento

→

Modelo NLP (TF-IDF + NB)

→

Regras de Negócio

→

Fila Prioritária

Etapas do Pipeline de Processamento

- Ingestão e Limpeza de Texto:** Os caracteres especiais são padronizados e o texto passa por conversão para minúsculas, garantindo que variações de digitação não prejudiquem a leitura do algoritmo.
- Vetorização (TF-IDF):** O texto é transformado em matrizes numéricas onde termos que indicam urgência ou atrito recebem pesos matemáticos proporcionalmente maiores em comparação com palavras comuns do vocabulário.
- Classificação Probabilística:** O classificador Multinomial Naive Bayes emite um *score* de confiança junto com a previsão (Positivo vs. Negativo).
- Motor de Regras Operacionais:** Uma camada lógica em Python avalia o sentimento em conjunto com palavras de gatilho para designar a prioridade exata de SLA na fila operacional.

5. Impacto nos Resultados Operacionais

A simulação de aplicação dessa arquitetura em um fluxo contínuo de atendimento demonstra ganhos expressivos na eficiência da equipe e na experiência final do cliente (NPS). Ao eliminar a triagem humana manual de casos óbvios, o tempo médio para o primeiro contato produtivo é drasticamente reduzido.

Tempo Médio de Triagem (Antes)

10.0 min

Tempo Médio com IA (Depois)

6.5 min

6. Próximos Passos & Roadmap de Evolução

O protótipo atual foi construído visando facilidade de implantação e alta interpretabilidade. Para os próximos ciclos de desenvolvimento técnico, estão planejadas as seguintes evoluções em ambiente de produção:

Fase do Roadmap	Ação Técnica	Objetivo de Negócio
Fase 1: Deploy API	Encapsular o modelo em uma API REST utilizando FastAPI ou Flask.	Permitir o consumo em tempo real por sistemas externos da central.
Fase 2: Integração CRM	Conectar os *endpoints* da API diretamente às ferramentas de Call Center (ex: Salesforce, Zendesk).	Alimentar automaticamente as tags e prioridades no *ticket* de atendimento.
Fase 3: Power BI / Metabase	Exportar logs diários de triagem para bancos relacionais (PostgreSQL/SQL Server).	Criar painéis executivos para acompanhamento do volume de insatisfação por turno.
Fase 4: Retraining Contínuo	Implementar esteira de re-treinamento com validação humana (Active Learning).	Adaptar o modelo a novos termos e gírias utilizadas pelos clientes ao longo do tempo.